PRÁCTICA 3B: CONSTRUCCIÓN DE UN SISTEMA DE CLASIFICACIÓN BASADO EN REGLAS DIFUSAS

Ingeniería del Conocimiento 3ºcurso
Curso académico 2023-2024

Yerson Caleb Yarhui Sarate

30/12/2023

Contents

1 Introducción y objetivos

El presente trabajo se centra en la generación de reglas difusas para la clasificación de datos, utilizando conjuntos difusos para representar las características de las instancias en un conjunto de datos. En particular, se aborda la construcción de conjuntos difusos para cada atributo, seguido por la generación de reglas difusas basadas en estos conjuntos. El enfoque se aplica a un conjunto de datos específico relacionado con las propiedades de las flores del dataset Iris.

- Construcción de Conjuntos Difusos:
  Se busca construir conjuntos difusos para cada atributo del conjunto de datos, tales como el largo y ancho del sépalo y pétalo. La construcción se realiza definiendo los universos de cada atributo y asignando funciones de pertenencia trianguulares (Bajo, Medio, Alto) a estos conjuntos.

- Generación de Reglas Difusas:
  Se propone generar reglas difusas a partir de los conjuntos difusos construidos. Para cada ejemplo en el conjunto de datos, se calculan los grados de pertenencia en los conjuntos difusos correspondientes a cada atributo. Luego, se selecciona el valor máximo de estos grados y se utiliza para determinar la etiqueta de la regla y su grado de certeza.

- Reducción de Reglas Redundantes:
  Con el fin de evitar reglas redundantes, se establece un proceso de reducción. En caso de reglas con etiquetas lingüísticas coincidentes, se selecciona la regla con el mayor grado de certeza, permitiendo obtener un conjunto de reglas más conciso y efectivo.

- Presentación de Resultados:
  Se presenta una base de reglas construidas, ilustrando ejemplos específicos de reglas difusas, y clasificaciones, especificando el accuracy y la matriz de confusión, generadas para diferentes combinaciones de valores de los atributos. Las reglas incluyen etiquetas lingüísticas, grados de certeza asociados y clase a la que clasifican.

El trabajo busca demostrar la utilidad de la lógica difusa y la generación de reglas en la clasificación de datos, específicamente aplicado al conjunto de datos de Iris.

2 Genereación de reglas

2.1 Construcción de conjuntos

Para construir los conjuntos, primero se obtienen los universos $\{RA, RB, RC, RD\}$ correspondientes a realizar RA = min(Largo Sepalo) a max(Largo Sepalo) incrementando con 0.1, RB = min(Ancho Sepalo) a max(Ancho Sepalo) incrementando con 0.1, RC = min(Largo Pétalo) a max(Largo Pétalo) incrementando con 0.1, RD = min(Ancho Pétalo) a max(Ancho Pétalo) incrementando con 0.1.
Por la especificación del problema originalmente se usa una función de pertenencia triangular, esta nos servirá para transformar los valores de los universos de cada atributo a conjuntos difusos, en nuestro caso utilizaremos los conjuntos difusos de Bajo, Medio, ALto para cada

atributo $\{A, B, C, D\} \approx \{'LargoSepalo', 'AnchoSepalo', 'LargoPetalo', 'AnchoPetalo'\}$.
Dado un referncial RX de el atributo X $\in features = A, B, C, D$ donde $minV = min(RX)$, $maxV = max(RX)$, $mmV = \frac{minV + maxV}{2}$.
Para construir el conjunto difuso X_{Bajo} se utilizará el RX tal que $X_{Bajo} = \mu_{Bajo}(RX)$

$$\mu_{\text{Bajo}}(x) = \begin{cases} 1, & \text{si } x = \text{minV} \\ 0, & \text{si } x > \text{mmV} \\ \frac{\text{mmV} - x}{\text{mmV} - \text{minV}}, & \text{si minV} < x \leq \text{mmV} \end{cases}$$

Para construir el conjunto difuso X_{Medio} se utilizará el RX tal que $X_{Medio} = \mu_{Medio}(RX)$

$$\mu_{\text{Medio}}(x) = \begin{cases} 1, & \text{si } x = \text{mmV} \\ 0, & \text{si } x < \text{minV} \\ 0, & \text{si} x > \text{maxV} \\ \frac{\text{maxV} - x}{\text{maxV} - \text{mmV}}, & \text{si mmV} < x <= \text{maxV} \\ \frac{x - \text{minV}}{\text{mmV} - \text{minV}}, & \text{si minV} <= x < \text{mmV} \end{cases}$$

Para construir el conjunto difuso X_{Alto} se utilizará el RX tal que $X_{Alto} = \mu_{Alto}(RX)$

$$\mu_{\text{Alto}}(x) = \begin{cases} 1, & \text{si } x = \text{maxV} \\ 0, & \text{si } x < \text{mmV} \\ \frac{x - \text{mmV}}{\text{maxV} - \text{mmV}}, & \text{si mmV} <= x < \text{maxV} \end{cases}$$

A con el universo RA

A-BAJO A-MEDIO A-ALTO

B con el universo RB

B-BAJO B-MEDIO B-ALTO

C con el universo RC

C-BAJO C-MEDIO C-ALTO

D con el universo RD

D-BAJO D-MEDIO D-ALTO

2.2 Construcción de reglas

Dado un ejemplo $X_i = \{largoSepalo_i, anchoSepalo_i, largoPetalo_i, anchoPetalo_i\}|X_i \in X$ nuestro conjunto de datos, obtenemos los posibles grados de pertenencia de los elementos de $X_{i,j}$ que serán 3 valores por atributo $j = 1..4$, estos valores los buscaremos en el conjunto difuso de cada atributo $A(RA == X_{i,1})$ por ejmplo. Es decir, $grados_A = A(RA == X_{i,1})$, $grados_B = B(RB == X_{i,2})$, $grados_C = C(RC == X_{i,3})$, $grados_D = D(RD == X_{i,4})$(Estos grados serán tripletes).
Una vez calculados los grados de pertenencia de cada atributo para el ejemplo X_i nos quedaremos con el valor máximo de el triplete que nos devuelve cada atributo difuso y con esos valores podremos calcular la etiqueta de la regla y el grado de certeza.
La etiqueta la calcularemos de manera que BAJO:1, MEDIO:2, ALTO:3, entonces $[valorMaximo_A, etiqueta_A] = max(grados_A)$, $[valorMaximo_B, etiqueta_B] = max(grados_B)$, $[valorMaximo_C, etiqueta_C] = max(grados_C)$ y $[valorMaximo_D, etiqueta_D] = max(grados_D)$.
Podremos calcular su grado de certeza que será una t-norma
$r_i = T(valorMaximo_A, valorMaximo_B, valorMaximo_C, valorMaximo_D)$ y también generaremos la regla $R_i = \{etiqueta_A, etiqueta_B, etiqueta_C, etiqueta_D, r_i, Y_i\}|Y_i \in clases \quad \& \quad clases = \{1 :' Iris-setosa', 2 :' Iris-versicolor', 3 :' Iris-virginica'\}$ donde Y_i indica la clase a la que pertenece la regla i.
Puede darse el caso de que existan reglas redundantes, es decir, $R_{i,1:4} == R_{j,1:4}|i \neq j$ donde coinciden las etiquetas lingüísticas para cada atributo, en este caso se diferenciarán en base a su quinto atributo que es su grado de certeza, y nos quedaremos con la regla que mayor grado de certeza tenga, y la otra la desecharemos, $R_{k,1:4} = R_{i,1:4}; R_{k,5:6} =$

$maximaCerteza(R_{i,5}, R_{j,5}), R_{maximaCerteza_{i,j},6}$ y eliminar R_i, R_j. Generariamos tantas reglas R_k como ejemplos $k = 1..numEjemplos$ haya en X. Y con la reducción de reglas redundantes conseguiríamos $t \leq k$ reglas.

2.3 Base de reglas construidas

Sabiendo que $clases = \{1 :' Iris - setosa', 2 :' Iris - versicolor', 3 :' Iris - virginica'\}$

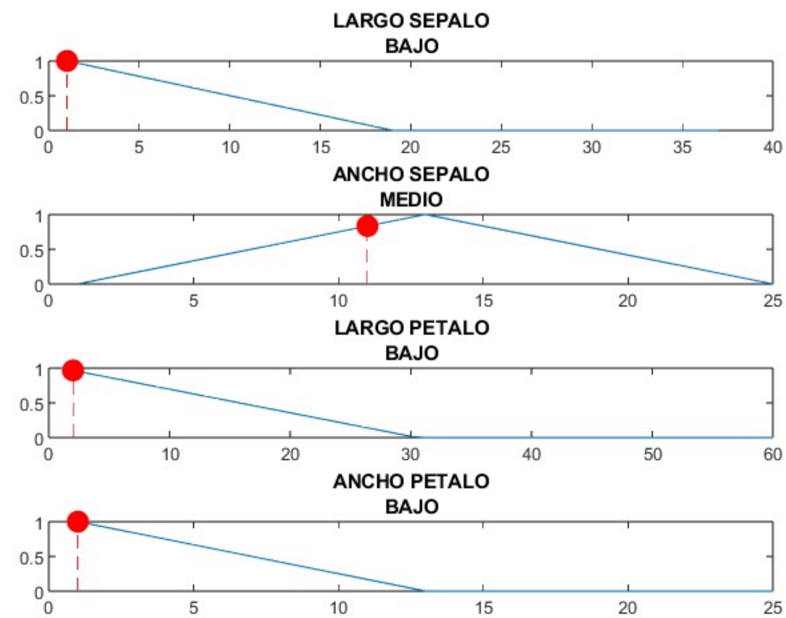

Figure 1: R1: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.81

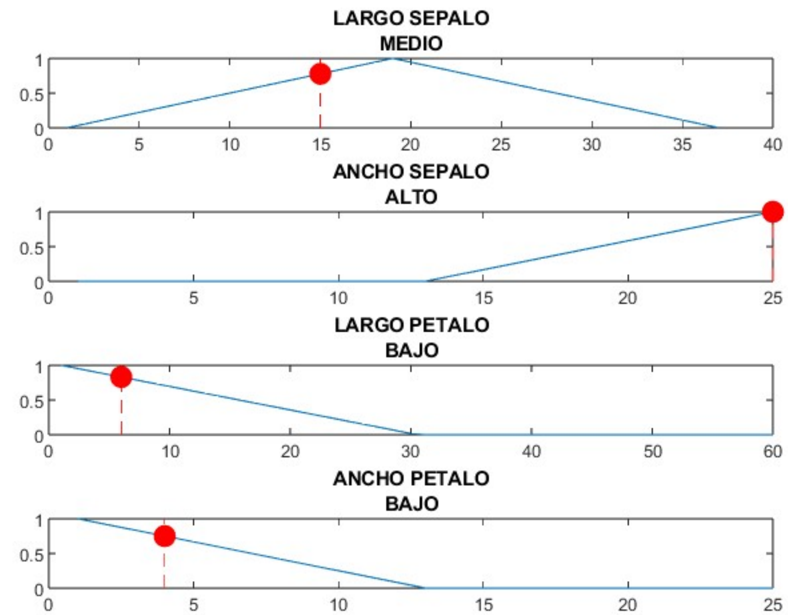

Figure 2: R2: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS ALTO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.48

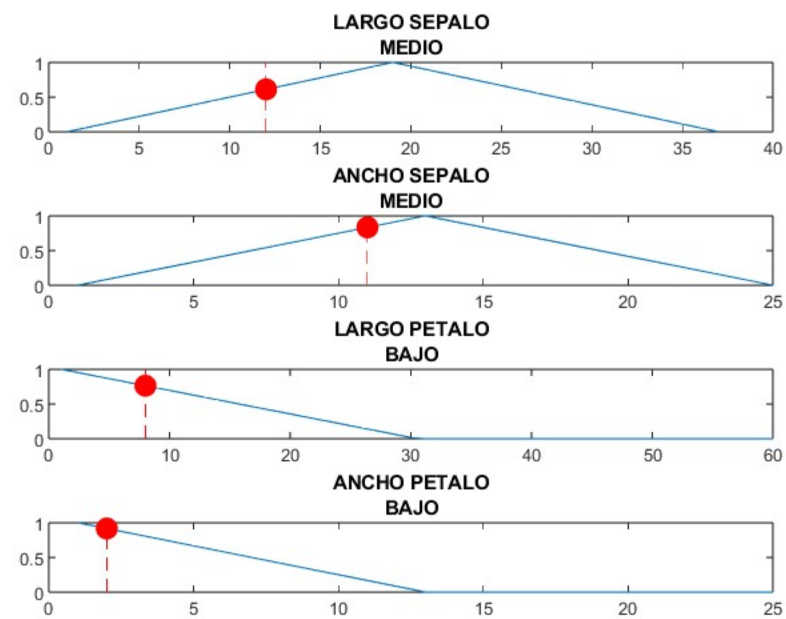

Figure 3: R3: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.36

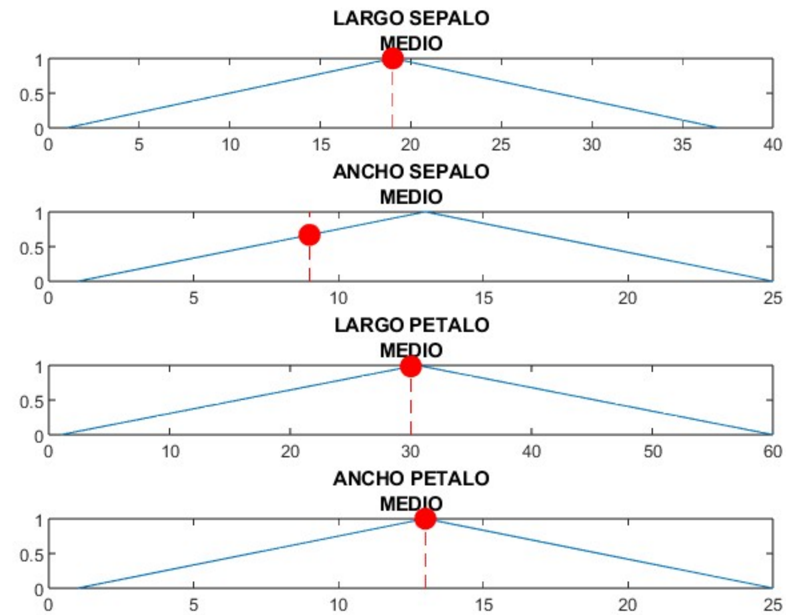

Figure 4: R4: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.66

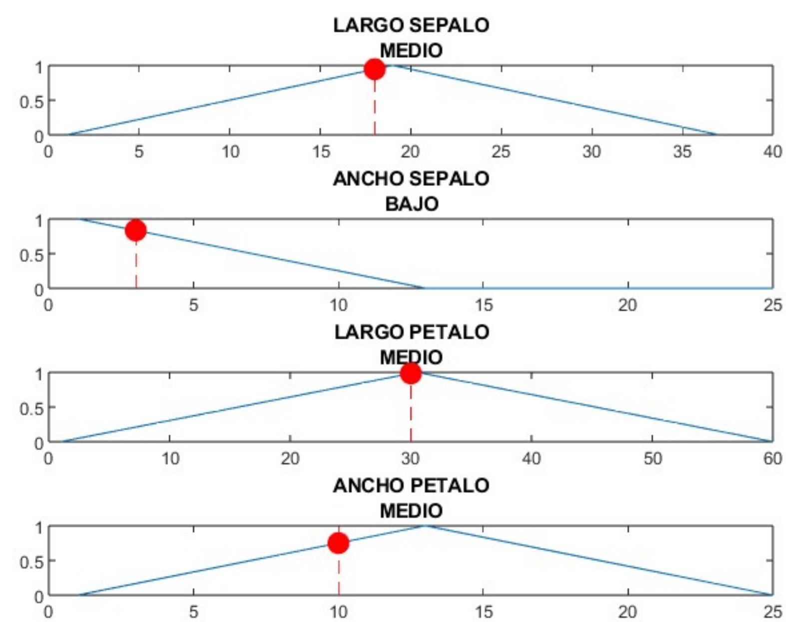

Figure 5: R5: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.58

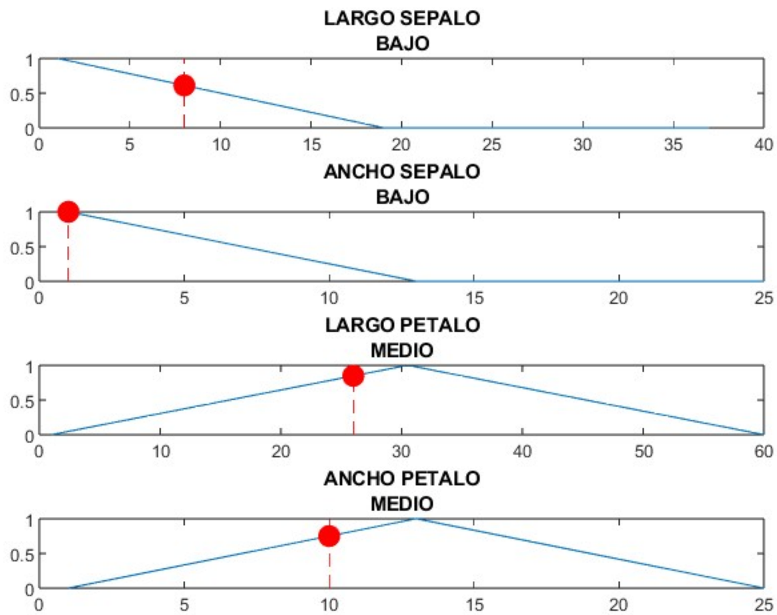

Figure 6: R6: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.39

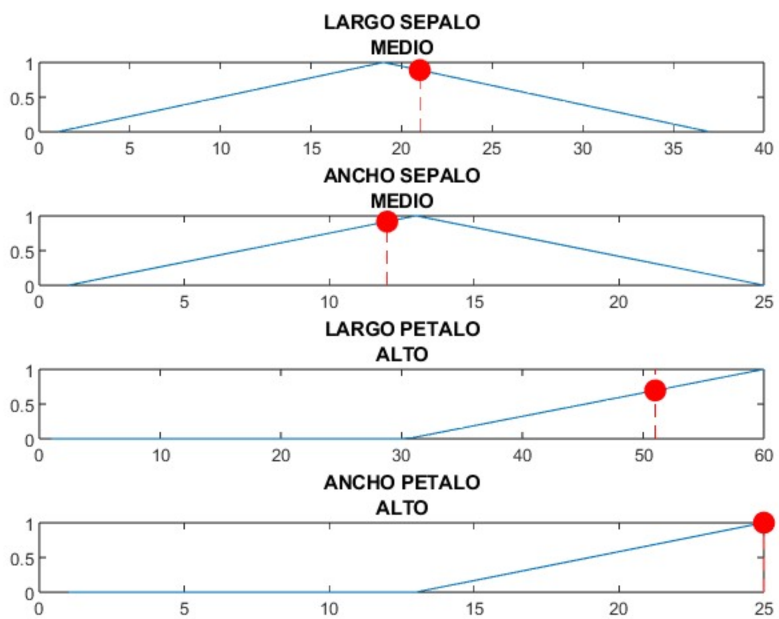

Figure 7: R7: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.57

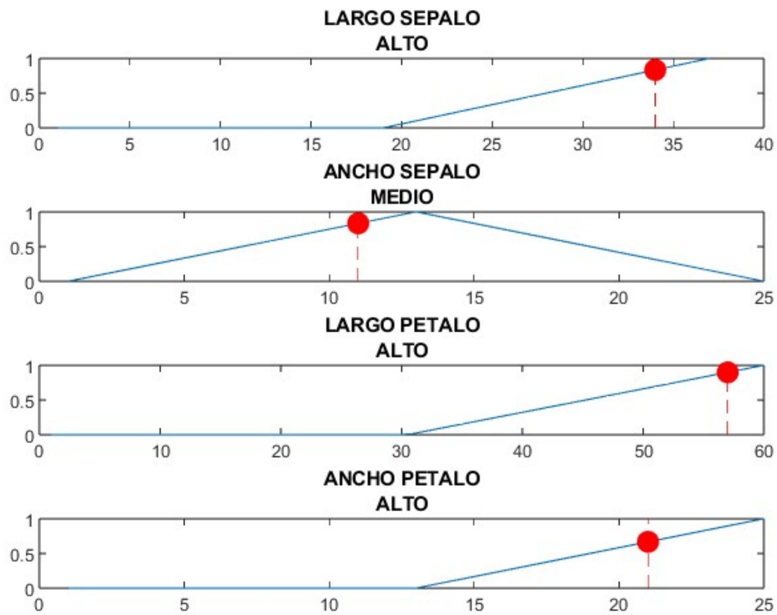

Figure 8: R8: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.42

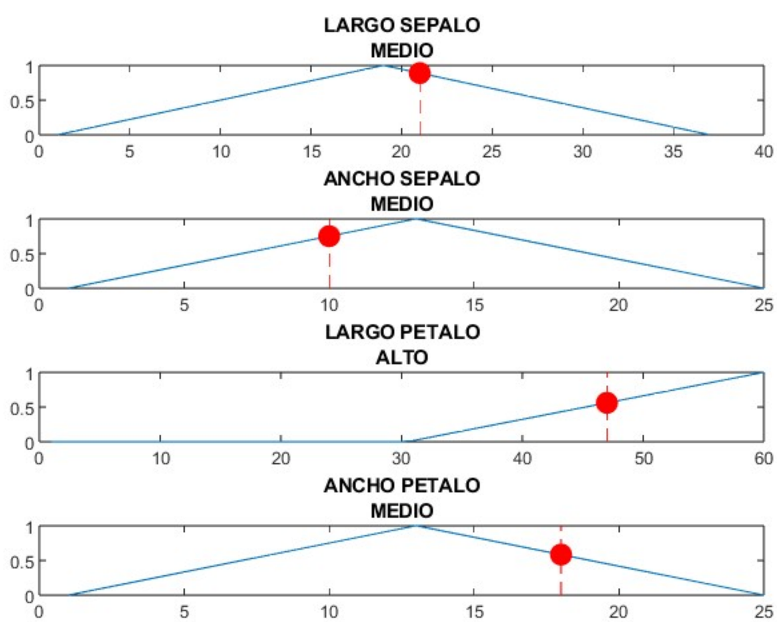

Figure 9: R9: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.22

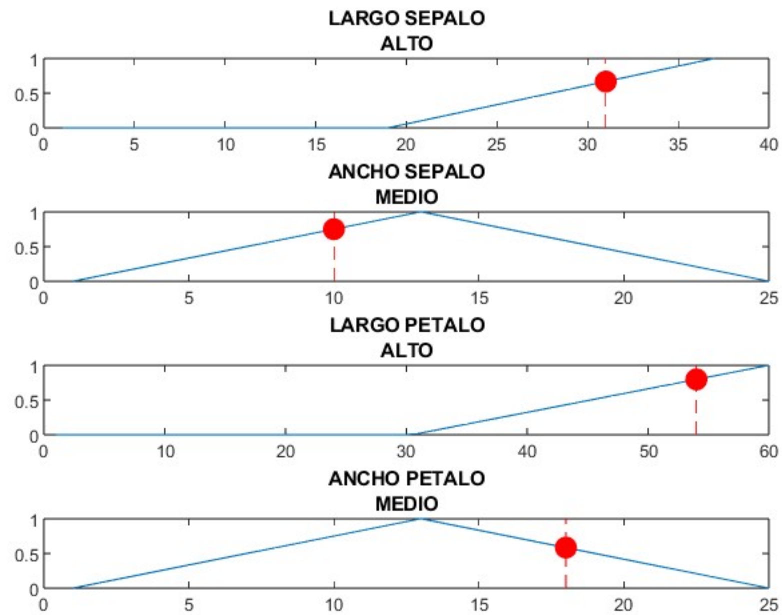

Figure 10: R10: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.23

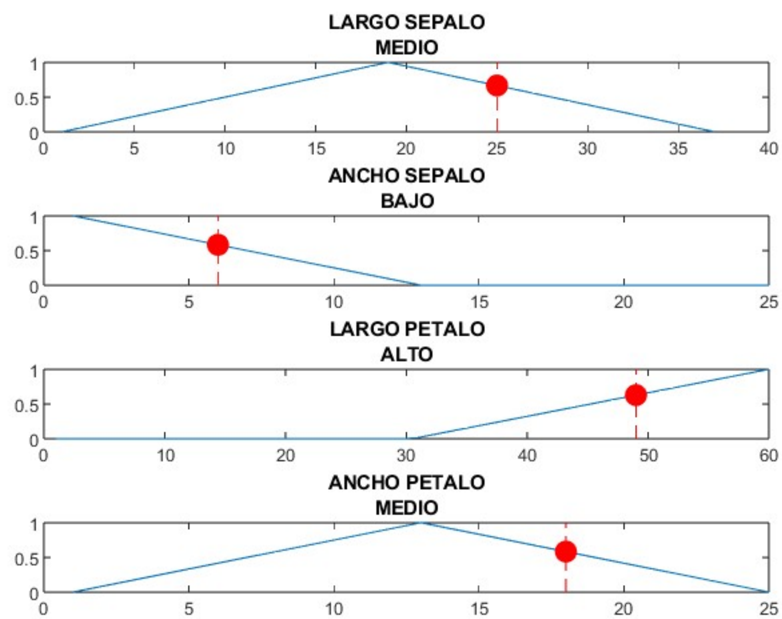

Figure 11: R11: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.14

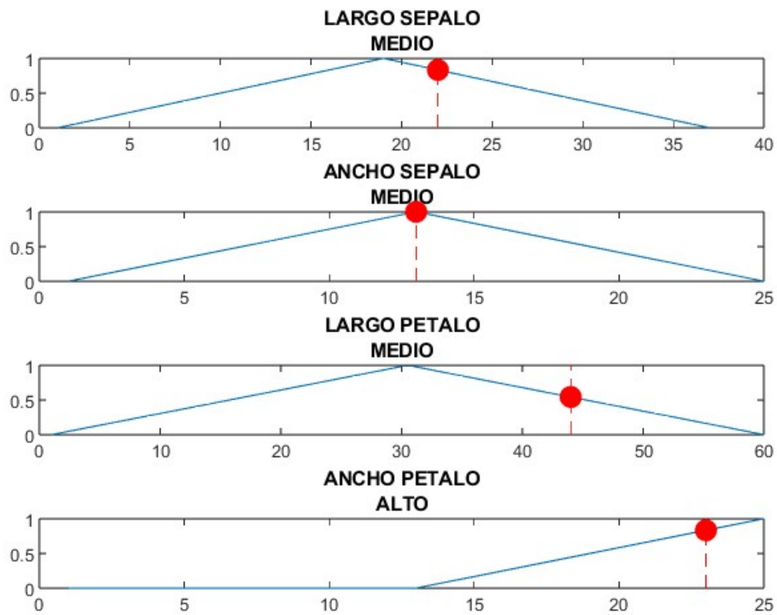

Figure 12: R12: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.38

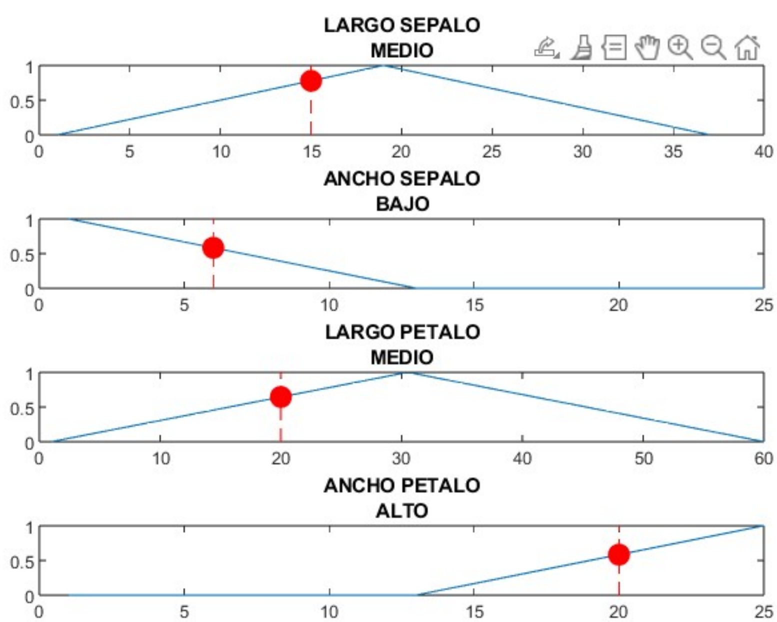

Figure 13: R13: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.17

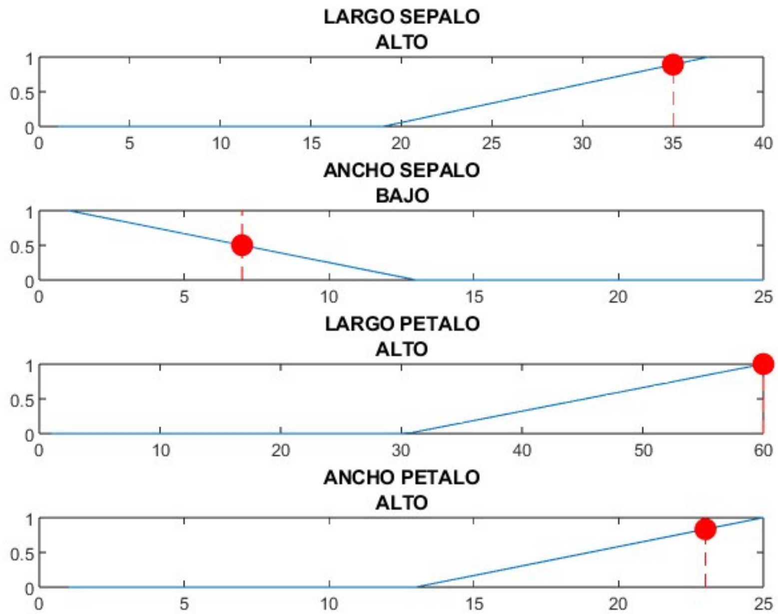

Figure 14: R14: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.37

3 Clasificación

3.1 Proceso Clasificación

Para este proceso necesitamos el conjunto de reglas generadas R_{14x6}, que en total son 14 reglas y 6 atributos, conjuntos $C = \{RA, RB, RC, RD, A, B, C, D\}$, y X_{test}, Y_{test}.
Se calculan los grados de compatibilidad de un ejemplo $X_i \in X_{test}$ para las 14 reglas, se calcularán los grados de pertenencia como en la construcción de reglas solo que el paso en el que se elige el máximo del triplete será intercambiado por elegir el de la etiqueta de la regla R_i, es decir, $gA = grados_A(R_{i,1})$, $gB = grados_B(R_{i,2})$, $gC = grados_C(R_{i,3})$, $gD = grados_D(R_{i,4})$.
Una vez obtenemos estos valores como si estuvieramos calculando el grado de certeza, el de compatibilidad $gComp_{14x1}$ también es la t-norma $gComp_i = gA * gB * gC * gD$.
Ahora calculamos el grado de asociación por reglas para un ejemplo, es decir, será otro vector columna $gAsoc_{14x1}$, donde se multiplica el grado de compatibilidad por la certeza $gAsoc_i = gComp_i * R_{i,5}$. Finalmente se obtiene un vector que habrá tantos elementos como clases k, asocClase, que obtendrá la media de grados de asociación por clase, es decir $asocClase_k = mean(gAsoc_{R_{t,6}==k}), k = 1..3, t = 1..14$.
El ejemplo X_i se clasificará como $clasePredicha_i = argmax_{c=1..3}(asocClase)$.
Este proceso se realiza por cada ejemplo $X_i \in X_{test}|i = 1..dimTest$. Después calculamos $acc = mean(clasePredicha == Y_{test})$, y obtenemos una matriz de confusión MC_{3x3}.

3.2 Valoración de los resultados

El resultado del accuracy es 85.3..%
Y la matriz de confusión es:

Valor predicho

Valor real		**Clase 1**	**Clase 2**	**Clase 3**
	Clase 1	25	0	0
	Clase 2	0	25	0
	Clase 3	0	11	14

Table 1: Matriz de confusión

El resultado del accuracy es muy bueno, aunque para entender un poco la clasificación se realizó una matriz de confusión, esta nos indica que para predicciones de clase 2 no es tan bueno ya que de 36 ejemplos, acertó 25 ejemplos que realmente eran de clase 2 pero fallo 11 ejemplos que realmente no eran clase 2 sino clase 3. Ha clasificado un 44% de ejemplos de clase 3 en clase 2. Buscaremos reducir este Falso Clase 2-3.
El único conflito que genera esta matriz es en la clasificación de clase 2 ya que confunde parte de clase 3 con clase 2. Si se tratará de un problema de clustering podríamos intentar maximizar la varianza intra-cluster para que puedan diferenciarse bien las clases y no exista ningún tipo de solapamiento fuerte.

4 Modificaciones del algoritmo

4.1 Modificación de la función de pertenencia a Gaussiana

Aplicando la modificación a la construcción de los conjuntos difusos de A, B, C, D si en vez de aplicar la función de pertenenecia aplicamos una función gaussiana,
$\mu = mean(RX);$
$\sigma = std(RX)/3;$
$BAJO = gaussmf(RX, [\sigma, min(RX)]);$
$MEDIO = gaussmf(RX, [\sigma, \mu]);$
$ALTO = gaussmf(RX, [\sigma, max(RX)]);$
,
donde $gaussmf(x, [\sigma, \mu]) =$

$$f(x|\mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right)$$

entonces, el número de reglas que se generarían en la construcción de reglas podría variar, y en este caso aumenta 1 regla a las 14 anteriores.
Reglas:
R1: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.71
R2: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS ALTO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.18

R3: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.05
R4: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.40
R5: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.33
R6: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.05
R7: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.01
R8: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.24
R9: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.12
R10: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.00
R11: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.01
R12: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.00
R13: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.03
R14: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.00
R15: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.03

El accuracy es 86.6..%
Y la matriz de confusión es:

		Valor predicho		
Valor real		**Clase 1**	**Clase 2**	**Clase 3**
	Clase 1	25	0	0
	Clase 2	0	25	0
	Clase 3	0	10	15

Table 2: Matriz de confusión

En este caso donde solo hemos modificado la construccion de los conjuntos difusos, de utilizar una función de pertenencia triangular a una función de pertenenecia gaussiana, obtenemos una ligera mejora en la clasificación de clase 2, ya que esta vez se ha equivocado en un 40% de los ejemplos de clase 3, un 4% menos que usando la función de pertenencia triangular.

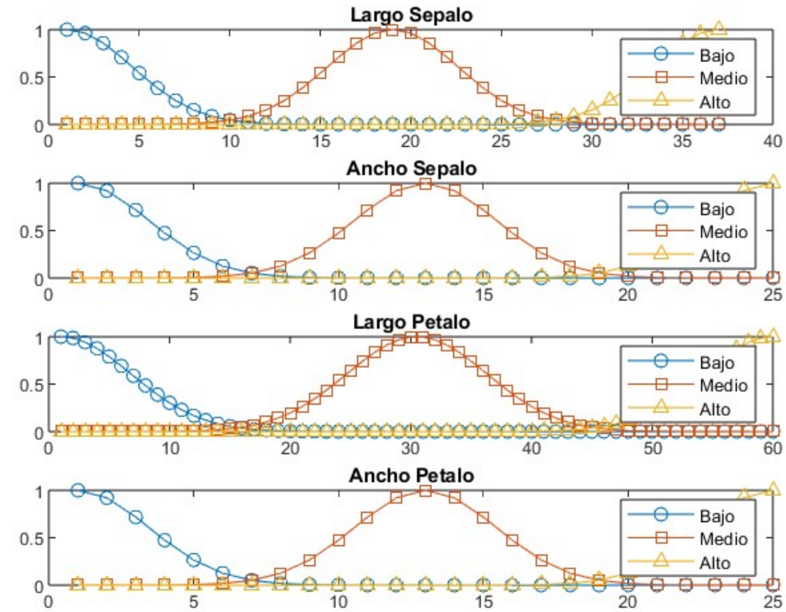

Figure 15: Así es como quedarían los conjuntos difusos A, B, C y D

4.2 Modificación de la función de pertenencia por gaussiana y en el calculo de grado de compatibilidad la t-norma de producto por Lukasiewizc

En la siguiente prueba lo que hacemos es usar los conjuntos formados con las funciones de pertenencia gaussianas y lo que modificaremos será la t-norma de el grado de compatibilidad, en vez de ser $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, producto) = gA*gB*gC*gD.$, ahora será $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, lukasiewizc) = max(0, gA+gB+gC+gD-|gA, gB, gC, gD| - 1)$.
Con este cambio el accuracy se reduce a 40%
Y la matriz de confusión es:

Valor real \ Valor predicho	**Clase 1**	**Clase 2**	**Clase 3**
Clase 1	25	0	0
Clase 2	20	5	0
Clase 3	25	0	0

Table 3: Matriz de confusión

El sistema de clasificación ha empeorado con este cambio ya que no acierta ningún ejemplo de la clase 3, con ejemplos de la clase 2 acierta solo un 20%. Tiende a confundir las clases con la Clase 1. Usar Lukasiewizc no ha mejorado la clasificación sino que la ha empeorado.

4.3 Modificación de la función de pertenencia por triangular y en el calculo de grado de compatibilidad la t-norma de producto por Lukasiewizc

En la siguiente prueba lo que hacemos es usar los conjuntos formados con las funciones de pertenencia triangular y lo que modificaremos será la t-norma de el grado de compatibilidad, en vez de ser $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, producto) = gA*gB*gC*gD.$, ahora será $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, lukasiewizc) = max(0, gA+gB+gC+gD-|gA, gB, gC, gD|-1)$ como en el anterior ejemplo.
Con este cambio el accuracy llega a 64% > 40% (usando función gaussiana y lukasiewizc.)
Y la matriz de confusión es:

Valor predicho

Valor real	**Clase 1**	**Clase 2**	**Clase 3**
Clase 1	25	0	0
Clase 2	8	17	0
Clase 3	17	2	6

Table 4: Matriz de confusión

El sistema de clasificación ha mejorado respecto al anterior con este cambio aunque no sea tan bueno como el primer cambio. Ahora sigue con la tendencia de clasificar los ejemplos mayormente como clase 1. Entonces, el problema es que con la función de pertenencia Lukasiewizc para los grados de compatibilidad no funciona muy bien.

4.4 Construcción de conjuntos con función de pertenencia triangular y función de grado de Compatibilidad por el Mínimo.

En la siguiente prueba lo que hacemos es usar los conjuntos formados con las funciones de pertenencia triangular y lo que modificaremos será la t-norma de el grado de compatibilidad, en vez de ser $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, producto) = gA*gB*gC*gD.$, ahora será $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, minimo) = min(gA, gB, gC, gD)$.
El accuracy = 81.3..%
Y la matriz de confusión es:

Valor predicho

Valor real	**Clase 1**	**Clase 2**	**Clase 3**
Clase 1	25	0	0
Clase 2	0	25	0
Clase 3	0	14	11

Table 5: Matriz de confusión

Esta clasificación es similar a la original, pero en esta fallamos más ejemplos de clase 3 y acertamos menos ejemplos de clase 3, esta vez un 56% de fallo en clase 3 puesto que lo clasificamos como clase 2. Las demás clases se clasifican correctamente.

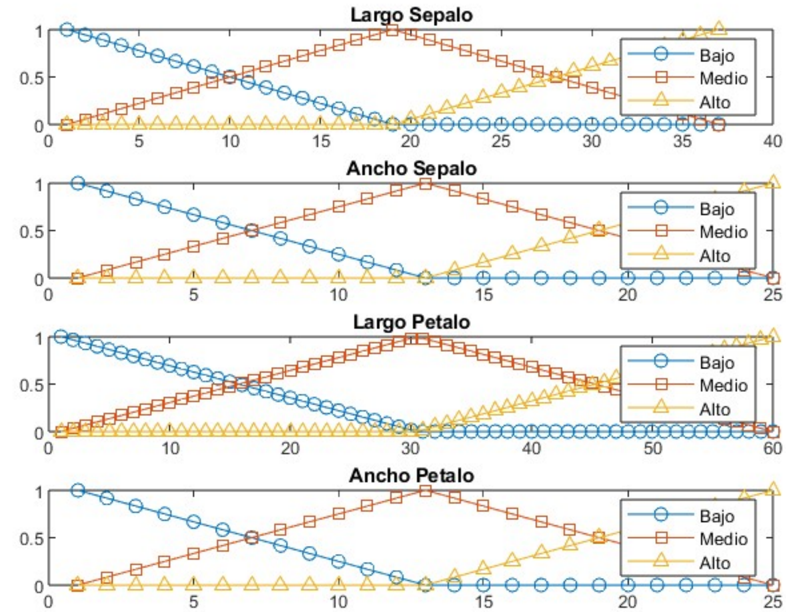

Figure 16: Así es como quedarían los conjuntos difusos A, B, C y D

4.5 Construcción de conjuntos con función de pertenencia trapezoidal y función de grado de Compatibilidad por el producto

Para construir los conjuntos de $X \in \{A, B, C, D\}$, usamos su referencial RX.
Tal que $X_{Bajo} = \mu_{Bajo}(RX)$, $X_{Medio} = \mu_{Medio}(RX)$ y $X_{Alto} = \mu_{Alto}(RX)$,
y en cuanto al grado de compatibilidad: $gComp_{14x1}|gComp_i = T(gA, gB, gC, gD, producto) = gA * gB * gC * gD$.
Dado que $minV = min(RX)$, $maxV = max(RX)$, $mmV = \frac{maxV+minV}{2}$
Para construir el conjunto difuso X_{Bajo} se utilizará el RX tal que $X_{Bajo} = \mu_{Bajo}(RX)$

$$\mu_{\text{Bajo}}(x) = \begin{cases} 1, & \text{si minV} <= x < \text{mean(minV, mmV)} \\ 0, & \text{si } x > \text{mmV} \\ \frac{\text{mmV}-x}{\text{mmV}-\text{mean(minV, mmV)}}, & \text{si mean(minV, mmV)} < x \leq \text{mmV} \end{cases}$$

Para construir el conjunto difuso X_{Medio} se utilizará el RX tal que $X_{Medio} = \mu_{Medio}(RX)$

$$\mu_{\text{Medio}}(x) = \begin{cases} 1, & \text{si mmV} <= x <= \text{mean(mmV, maxV)} \\ 0, & \text{si } x < \text{mean(minV, mmV)} \\ 0, & \text{si} x > \text{maxV} \\ \frac{\text{mmV}-x}{\text{mmV}-\text{mean(minV, mmV)}}, & \text{si mean(minV, mmV)} <= x < \text{mmV} \\ \frac{x-\text{minV}}{\text{mmV}-\text{minV}}, & \text{si minV} <= x < \text{mmV} \end{cases}$$

Para construir el conjunto difuso X_{Alto} se utilizará el RX tal que $X_{Alto} = \mu_{Alto}(RX)$

$$\mu_{\text{Alto}}(x) = \begin{cases} 1, & \text{si } x = \text{maxV} \\ 0, & \text{si } x < \text{mean(mmV, maxV)} \\ \frac{x - \text{mean(mmV, maxV)}}{\text{maxV} - \text{mean(mmV, maxV)}}, & \text{si mean(mmV, maxV)} <= x < \text{maxV} \end{cases}$$

Las reglas que me ha generado son 17 en total:
R1: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 1.00
R2: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS BAJO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.50
R3: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.56
R4: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS ALTO AND Largo Petalo IS BAJO AND Ancho Petalo IS BAJO THEN Clase 1 con Certeza = 0.56
R5: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 1.00
R6: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 1.00
R7: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 1.00
R8: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS BAJO THEN Clase 2 con Certeza = 0.35
R9: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS BAJO THEN Clase 2 con Certeza = 0.44
R10: IF Largo Sepalo IS BAJO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS MEDIO THEN Clase 2 con Certeza = 0.37
R11: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.67
R12: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.24
R13: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.20
R14: IF Largo Sepalo IS MEDIO AND Ancho Sepalo IS BAJO AND Largo Petalo IS MEDIO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.37
R15: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS MEDIO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.34
R16: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS ALTO THEN Clase 3 con Certeza = 0.52
R17: IF Largo Sepalo IS ALTO AND Ancho Sepalo IS BAJO AND Largo Petalo IS ALTO AND Ancho Petalo IS MEDIO THEN Clase 3 con Certeza = 0.37

Esta vez obtenemos un accuracy = 68%

Y la matriz de confusión es:

		Valor predicho		
Valor real		**Clase 1**	**Clase 2**	**Clase 3**
	Clase 1	25	0	0
	Clase 2	8	21	4
	Clase 3	0	20	5

Table 6: Matriz de confusión

En este caso, usando estas funciones de pertenencia obtenemos un accuracy más o menos bueno, el problema radica en la distinción de las clases 2 y 3, ya que vuelve a clasificar falsamente las clases 3 como clase 2, de hecho un 80% de los que son realmente clase 3 están clasificados como clase 2. Por tanto, no nos intersa utilizar este modelo.

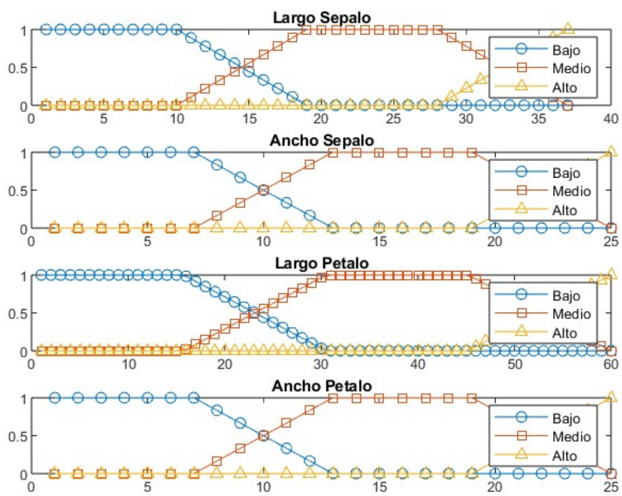

Figure 17: Así es como quedarían los conjuntos difusos A, B, C y D

5 Conclusión final

En conclusión, el trabajo realizado ha explorado diversas modificaciones en el algoritmo de clasificación difusa, evaluando su impacto en la precisión y la capacidad de clasificación del sistema. Se han probado ajustes en las funciones de pertenencia, gaussianas, triangulares o trapezoidales y en la t-norma de producto, mínimo o Lukasiewicz, observando cómo estos cambios afectan el rendimiento del modelo.

En la configuración original, se logró un accuracy del 85.3%, aunque se identificó un problema en la clasificación de la Clase 2, donde hubo cierta confusión con la Clase 3. Las modificaciones posteriores incluyeron cambios en la función de pertenencia, la t-norma de producto, mínimo o Lukasiewicz y la introducción de funciones gaussianas, trapezoidales o triangulares. Estos ajustes generaron resultados variados, con mejoras en algunos casos, pero también empeoramientos notables en otros.

Se destaca que, al emplear funciones de pertenencia gaussiana, se observó una ligera mejora en la clasificación de la Clase 2. Sin embargo, al cambiar la t-norma de producto por Lukasiewicz, se obtuvo un descenso significativo en la precisión del modelo.

En general, las modificaciones no lograron resolver completamente el problema de confusión entre las Clases 2 y 3. Se encontró que algunas configuraciones generaban resultados aceptables en términos de accuracy, pero persistía la tendencia a clasificar erróneamente ejemplos de la Clase 3 como Clase 2.
Aún así, el mejor modelo generado fue la combinación de la construcción de conjuntos con la función gaussiana y la t-norma producto para el grado de compatibilidad.

En futuras investigaciones, podría ser útil explorar enfoques adicionales para mejorar la distinción entre las Clases 2 y 3, como ajustes más finos en las funciones de pertenencia o la consideración de otros métodos de clasificación difusa. Además, la evaluación de otras métricas de rendimiento y la aplicación de técnicas de validación cruzada podrían proporcionar una comprensión más completa del rendimiento del modelo en diferentes conjuntos de datos.